

Yapay Sinir Ağları

1.Ödev

22.11.2020

Mehmet Şerbetçioğlu -- 040160056

Ahmet Hulusi Tarhan -- 040170738

Soru 1:

Öncelikle bir “DataPoints” obje sınıfı oluşturuldu. Bu sınıfın içinde koordinat, anahtar, veri sınıfı ve verinin kullanılacağı küme bilgileri mevcut. Ek olarak bu bilgilerin değişmesini sağlayacak ve koordinatın vektörel uzunluğunu verecek fonksiyonlar var.

```
15 class DataPoints:
16     #DataPoints obje sınıfında koordinat, anahtar, veri sınıfı ve küme bilgileri mevcut.
17     def __init__(self, Coordinate, Key, DataClass, Domain):
18         self.Coordinate = Coordinate
19         self.Key = Key
20         self.DataClass = DataClass
21         self.Domain = Domain
22
23     #
24     def setCoordinate(self, Coordinate):
25         self.Coordinate = Coordinate
26
27     def setClass(self, DataClass):
28         self.DataClass = DataClass
29
30     def setDomain(self, Domain):
31         self.Domain = Domain
32
33     #Verinin koordinat vektörünün büyüklüğünü veren fonksiyon.
34     def CoordinateMag(self):
35         return np.linalg.norm(self.Coordinate)
```

İlk olarak kullanılacak verilerin saklanacağı yeri, veri sayısını ve verilerden bilgi çekebilecek basit fonksiyonlar tanımlandı.

```
381 __location__ = os.path.realpath(os.path.join(os.getcwd(), os.path.dirname(__file__)))
382 dataFile = os.path.join(__location__, 'Data.pkl')
383 max_epoch = 40
384
385 GetCoordinate = attrgetter('Coordinate')
386 GetKey = attrgetter('Key')
387 GetDataClass = attrgetter('DataClass')
388 GetDomain = attrgetter('Domain')
```

Ardından belirtilen lokasyonda bir veri dosyası var mı diye kontrol edilir. Eğer belirtilen dosya bulunmaktaysa dosyadaki veriler “objList” listesine yüklenir. Ardından bu listedeki verilerin beşinci boyut koordinatları ve anahtarlarıyla yeni bir sözlük meydana getirilir.

```
390 if os.path.exists(dataFile):
391     objList = loadList(dataFile)
392     allDict = newDict(objList)
```

```

42 #File lokasyonundaki listeyi çeker.
43 def loadList(File):
44     DataList = []
45     with open(File, 'rb') as f:
46         DataList = pickle.load(f)
47     return DataList

```

```

67 #Girilen listeden koordinatın beşinci boyut elemanı ve anahtar bilgilerini çeken bir sözlük oluşturur.
68 def newDict(List):
69     d = {}
70     for obj in List:
71         a = GetCoordinate(obj)
72         k = GetKey(obj)
73         d[k] = a[4]
74     #Oluşturulan sözlük lineer ayrıştırılabilirlik için kullanılacak.
75     return d

```

Eğer böyle bir veri yoksa, belirtilen veri sayısında yeni veri oluşturulur. Bu verilerin koordinatları noktadan sonra dört basamaklı, (-5,5) aralığında rastgele seçilir. Oluşturulan veriler “objList” listesine kaydedilir. Bu listeye yeni bir sözlük oluşturulur. Daha sonra “distClass” komutuyla listedeki veriler yarı yarıya beşinci boyut elemanlarının büyüklüğüne göre iki sınıfa ayrılır. Ardından eğitim ve test kümeleri dağıtılır ve son olarak veri kaydedilir. “distClass” fonksiyonunda dördüncü argümanda False kullanılırsa veriler rastgele sınıflara dağıtılıp lineer ayrıştırılabilir olması kesinleşmeyecektir.

```

394 else:
395     objList = newData(max_epoch)
396     allDict = newDict(objList)
397     distClass(max_epoch, allDict, objList, True)
398     distDomain(objList)
399     saveData(objList, dataFile)

```

```

56 #ep newData: newData boyutlu koordinat oluşturur.
57 def newData(epoch):
58     DataList = []
59     for i in range(epoch):
60         #Koordinatlar (-1,1) aralığında noktadan sonra 4 basamaklı sayılardan oluşmakta. Uniform dağılımla seçiliyorlar.
61         Coord = 10*np.random.random_sample(5,) - 5
62         Coord = np.around(Coord, decimals = 4)
63         #Kordinatlarla yeni bir veri listesi oluşturur. Yeni verilerin anahtarları iterasyon sayısına eşit olacak ve birbirinden farklı olacaktır.
64         DataList.append(DataPoints(Coord, i, 0, "0"))
65     return DataList

```

```

56 #"epoch" kez yeni beş boyutlu koordinat oluşturur.
57 def newData(epoch):
58     DataList = []
59     for i in range(epoch): ...
65     return DataList

```

```

67 #Gir newDict: newDict dinatin beşinci boyut elemanı ve anahtar bilgilerini çeken bir sözlük oluşturur.
68 def newDict(List):
69     d = {}
70     for obj in List:
71         a = GetCoordinate(obj)
72         k = GetKey(obj)
73         d[k] = a[4]
74     #Oluşturulan sözlük lineer ayrıştırılabilirlik için kullanılacak.
75     return d

196 #Veri sınıflarını dağıtan fonksiyon
197 def distClass(epoch, Dict, List, Lin):
198     #Lineerizasyon gerçekleşmesi için Lin argümanı doğru olmalıdır.
199     if Lin == True:
200         totalDict = Dict
201         minDict = {}
202         #Verilen sözlüğü kullanarak verilerin koordinatlarının beşinci boyut elemanlarını büyüklüklerine göre ikiye ayırır.
203         #Bu lineer ayrıştırılmanın kesinlikle mümkün olmasını sağlar.
204         for i in range(round(epoch/2)):
205             key_min = min(totalDict.keys(), key=(lambda k: totalDict[k]))
206             minDict[key_min] = totalDict[key_min]
207             del totalDict[key_min]
208         for obj in List:
209             k = GetKey(obj)
210             #Minimum sözlüğündeki değerlerin veri sınıfını 1'e, diğerlerini -1'e atar.
211             if k in minDict.keys():
212                 obj.setClass(1)
213             else:
214                 obj.setClass(-1)
215
216     #Lin argümanı doğru değilse girilen liste çekilir, karıştırılır ve sınıflara dağıtılır.
217     elif Lin == False:
218         totalDict = Dict
219         keys = list(totalDict.keys())
220         random.shuffle(keys)
221         Dict1 = dict(list(totalDict.items())[len(totalDict)//2:])
222         Dict2 = dict(list(totalDict.items())[:len(totalDict)//2])
223         for obj in List:
224             k = GetKey(obj)
225             #Değerleri rastgele bir şekilde farklı veri sınıflarına atar.
226             #Bununla birlikte lineer ayrıştırılabilir bir veri elde etme ihtimali fazlasıyla düşük olacaktır.
227             if k in Dict1.keys():
228                 obj.setClass(1)
229             elif k in Dict2.keys():
230                 obj.setClass(-1)
231             else:
232                 print("None data class detected.")

37 #Data dosyasını File lokasyonuna kaydeder.
38 def saveData(Data, File):
39     with open(File, 'wb') as f:
40         pickle.dump(Data, f)

```

Bu şekilde veriler oluşturulup sınıflara ve kümelere dağıtılmış olur. Eğitimi başlatmak için $w1 = [1, 1, 1, 1, 1, 1]$ ağırlığı seçelim. Öncelikle daha önce eğitilmiş ve test kümelerini başarıyla sınıflandırmış DomainEx1 kümesiyle test yapalım.

```

401 #1'lerden oluşan bir ağırlık vektörü.
402 w1 = [1, 1, 1, 1, 1, 1]
403
404 #Önceden atanmış bir test-eğitim kümesi.
405 #w1 = [1, 1, 1, 1, 1, 1] için 22 iterasyonda eğitilmekte ve son ağırlık w = [1.5964 0.8325 2.1872 -1.2123 -21.1314 23].
406 domainFile1 = os.path.join(__location__, 'DomainEx1.pkl')
407 domainFile2 = os.path.join(__location__, 'DomainEx2.pkl')
408 testnum = 1
409 #objList listesindeki verileri w1 = [1 1 1 1 1 1] ilk ağırlığı ve c = 1 öğrenme hızı ile, maksimum 80 iterasyon sürece şekilde eğiten fonksiyon.
410 #DomainEx1.pkl dosyasındaki eğitim-test kümesi dağılımlarını çekip verilere işler.
411 print("\n\nTest number:", testnum, " _"*150, "\n")
412 testnum += 1
413 insertDomain(objList, domainFile1)
414 extractDomain(objList, domainFile2)
415 Inf = process(objList, w1, 1, max_epoch*2, domainFile2)
416 print((" _"*165, "\n"))

```

İlk olarak w1, DomainEx1 dosya lokasyonu ve DomainEx2 dosya lokasyonu tanımlanır. Burada DomainEx2 dosyasının amacı DomainEx1in değişmemesidir. DomainEx2, DomainEx1i kopyalar ve eğitim DomainEx2 ile başlar. Kümeler anahtarlarıyla birlikte kaydedilip tekrar yüklenirken anahtarları kullanılarak verilerle eşlenirler.

```

268 #Verilerin küme bilgisini "domainFile" lokasyonundan çeker.
269 def insertDomain(List, domainFile):
270     for obj in List:
271         k = GetKey(obj)
272         domainId = loadDict(domainFile)
273         obj.setDomain(domainId[k])

```

```

258 #Verilerin küme bilgisini "domainFile" lokasyonunda saklar.
259 def extractDomain(List, domainFile):
260     domainId = {}
261     for obj in List:
262         k = GetKey(obj)
263         dom = GetDomain(obj)
264         domainId[k] = dom
265     saveData(domainId, domainFile)
266     return domainId

```

Daha sonra işlemlerimiz başlar. Öncelikle bazı değişkenler tanımlanır. Fonksiyonun argümanında bir veri kümesi olup olmadığına bakılır. Eğer varsa ve veri dosyası bulunuyorsa dosyadaki kümeler kullanılır. Argümanda belirtilip dosyası bulunmuyorsa kümeler dağıtılıp yeni dosya oluşturulur. Eğer argüman "None" olarak girilmişse sadece kümeleri dağıtır, dosya yüklemez ve oluşturmaz. Kümeler ilk seferde rastgele bir şekilde dağıtılır.

```

315 def process(objList, w, c, maxiter, domainFile):
316     i = 0
317     failedTestCount = 0
318     totalEdError = 0
319     wantedInfo = []
320     w = np.array(w)
321     #Önceden belirli bir eğitim-test kümesi dağılımı yapar. Yukarıda belirtilen domainFile'deki eğitim-test kümesini çeker.
322     if domainFile != None:
323         if os.path.exists(domainFile):
324             insertDomain(objList, domainFile)
325         else:
326             distDomain(objList)
327             extractDomain(domainFile)
328     #Eğer önceden belirli bir eğitim-test kümesi yoksa, girilen datayı dağıtır. Bu sayede kümeleri belirtilmeyen her veri rastgele kümelere dağıtılır.
329     else:
330         distDomain(objList)

```

```

77 #Eğitim ve test kümelerine rastgele dağıtım gerçekleştirir.
78 def distDomain(List):
79     shuffle = random.sample(range(0, len(List)), 40)
80     testArr = np.split(shuffle, [15])[0]
81     educationArr = np.split(shuffle, [15])[1]
82     for obj in List:
83         if obj.Key in testArr:
84             obj.setDomain("test")
85         elif obj.Key in educationArr:
86             obj.setDomain("education")
87         else:
88             continue

```

Daha sonra eğitim başlatılır. Eğitim sonucu ilk ağırlık, iterasyon sayısı, son ağırlık ve iterasyondaki değişim sayısının bulunduğu bir liste alınır. Eğitimdeki son ağırlık, bir sonraki eğitimde ilk ağırlık olmak üzere güncellenir. Eğer iterasyon sayısı -1'se, yani iterasyon sayısı verilen maksimum iterasyon sayısını geçmişse eğitim başarısız sayılır. Daha sonra eğitimle elde edilen ağırlık test aşamasına girer. Buradan testte gerçekleşen hata miktarı alınır. Eğer hiç hata alınmamışsa döngüden çıkılır ve eğitim tamamlanır. Fakat test aşamasında hata görüldüyse test ve eğitim kümeleri dengelenir, başarısız test sayısı 1 artırılır. Eğer bu işlem "maxiter" sayısından fazla kez gerçekleşirse eğitim durdurulup başarısız sayılır.

```

305 #Eğitim ve test işlemlerinin gerçekleştiği fonksiyon
306 def process(objList, w, c, maxiter, domainFile):
307     i = 0
308     failedTestCount = 0
309     totalError = 0
310     wantedInfo = []
311     w = np.array(w)
312     #Önceden belirli bir eğitim-test kümesi dağılımı yapar. Yukarıda belirtilen domainFile'deki eğitim-test kümesini çeker.
313     if domainFile != None:
314         #Eğer önceden belirli bir eğitim-test kümesi yoksa, girilen datayı dağıtır. Bu sayede kümeleri belirtilmeyen her veri rastgele kümelere dağıtılır.
315     else:
316
317     while i < 1:
318         #Eğitim ve test kümelerinin eleman sayılarını gösterir. Debug amaçlı
319         ""domainTest(objList)""
320
321         #Eğitimi başlatır ve ilk ağırlık, eğitimin sonlandığı iterasyon sayısı, son ağırlığı ve her iterasyon için iterasyondaki hata sayısını verir.
322         final = educate(objList, w, c, maxiter)
323
324         #Her iterasyonda toplam hatayı verir. Karşılaştırmada kullanılacak.
325         totalError = final[3]
326
327         #Verilerin test kümesinden geçmemesi durumu için w1 ağırlığını eğitilen ağırlığa esitler. Sonraki eğitimde ilk ağırlık olarak bu ağırlık kullanılır.
328         w = final[2]
329
330         #Eğitim belirlenen iterasyonda sonuçlanmıyorsa eğitilemediğine dair hata verir. Bu büyük ihtimalle verinin lineer ayrıştırılamaz olduğunu gösterir.
331         if final[1] == -1:
332             print("Education failed and likely impossible.")
333             break
334
335         #Eğitilen ağırlık test fonksiyonuna girilir. Burada ağırlık değişmez ve dönüt olarak hata veren veri sayısı alınır.
336         errorCount = test(objList, final[2])
337         print("Tested error count of ", failedTestCount + 1, "th education is ", errorCount)
338
339         #Eğer test sonrası hata alınmadıysa döngüden çıkar.
340         if errorCount == 0:
341             i += 1
342
343         #Testten geçemiyse veri balanceDomain fonksiyonuna girilir ve test kümesi ve eğitim kümesi birer eleman değişir. Bu değişim iki sınıfın da elemanı olacak şekilde
344         #ağırlık koyularak yapılır ancak yine de rastgele bir değişimdir. Ayrıca kümeler değiştiği için iterasyon başına hatayı sıfırlar.
345         else:
346             balanceDomain(objList)
347             failedTestCount += 1
348             if failedTestCount > maxiter:
349                 print("Education failed and likely impossible.")
350                 break

```

Eğitimi başlatırken veriler, ilk ağırlık, eğitim hızı ve maksimum iterasyon sayısı alınır. Eğer ağırlık geçerli değilse rastgele bir ağırlık atanır. Bunun için getrandomw fonksiyonuyla ortalama değeri 0 ve standart sapması 1 olan normal dağılımlı altı boyutlu bir w vektörü üretilir. İlk ağırlık belirlenir, finaliter değişkeni, iterasyon sayısının maksimumu aşması ihtimaliyle -1'e atanır. Eğitim kümesi elemanları listesi oluşturulur ve eğitim başlar.

```

254 #Eğitim fonksiyonu
255 def educate(List, w, eSpeed, maxiter):
256     educateList = []
257     final = []
258     totalEdError = 0
259
260     #Geçerli bir ağırlık vektörü verilmemişse rastgele bir ağırlık vektörü seçer.
261     if w.size != 6:
262         #Eğitime başlanılan ağırlığın çıktısını verir.
263         print("First weight:", np.around(w, decimals = 4))
264         firstw = w
265         finaliter = -1
266         #Verilerin içinden eğitim kümesine ait elemanları çeker.
267         for obj in List:
268             if GetDomain(obj) == "education":
269                 educateList.append(obj)
270
191 #Normal dağılımlı rastgele bir ağırlık vektörü atar.
192 def getrandomw(mean, scale):
193     w = np.random.normal(mean, scale, 6)
194     return w

```

Eğitim kümesi “maxiter” kez eğitilir. Bu sayı aşılsa “process” fonksiyonuna son iterasyon sayısı “-1” olarak döner ve eğitim başarısız sayılır. Öncelikle iterasyondaki değişim sayısı 0’a eşitlenir. Eğitim kümesindeki her veri için bias koordinatı eklenir. Daha sonra w ağırlık vektörü ile $v = wT \cdot x$ işlemi yapılır. Elde edilen v 0’dan büyükse y = 1, küçükse y = -1 aktivasyon fonksiyonu tanımlanır. yd değeri verinin sınıfıyla eşitlenir. Daha sonra $w = w + (c/2) \cdot (y_d - y) \cdot x$ perceptron algoritması kullanılarak her veri için ağırlık vektörü güncellenir. y değerinin yd’den farklı çıkması durumunda değişim sayısı 1 artırılır. Bu şekilde tüm eğitim kümesi üzerinden geçildiğinde bir eğitim iterasyonu tamamlanmış olur. Eğer iterasyon sonucunda değişim sayısı 0 bulunursa son iterasyon ve son ağırlık çekilip eğitim durdurulur. “process” fonksiyonuna ilk ağırlık, iterasyon sayısı, son ağırlık ve son iterasyondaki toplam hata bilgileri döner.


```

255 def educate(List, w, eSpeed, maxiter):
256     educatelist = []
257     final = []
258     totalEdError = 0
259
260     #Geçerli bir ağırlık vektörü verilmemişse rastgele bir ağırlık vektörü seçer.
261 > if w.size != 6: ...
263     #Eğitime başlanılan ağırlığın çıktısını verir.
264     print("First weight:", np.around(w, decimals = 4))
265     firstw = w
266     finaliter = -1
267     #Verilerin içinden eğitim kümesine ait elemanları çeker.
268     for obj in List:
269         if GetDomain(obj) == "education":
270             educatelist.append(obj)
271
272     for i in range(maxiter):
273         changeCount = 0
274         #Eğitim iterasyonu terasyon döngüsü
275         for obj in educatelist:
276             #Bias terimini verinin koordinatına ekler.
277             biasCoord = np.concatenate((GetCoordinate(obj),[1]))
278
279             #Perceptron eğitim algoritması
280             v = np.dot(w, biasCoord)
281             if v > 0:
282                 y = 1
283             else:
284                 y = -1
285             yd = GetDataClass(obj)
286             w = w + (eSpeed/2)*(yd - y)*biasCoord
287             w = np.around(w, decimals = 4)
288
289             #Değişim gerçekleştiyse bir iterasyondaki değişim sayısına bir ekler.
290             if yd != y:
291                 changeCount += 1
292         totalEdError += changeCount
293         #Eğitim sırasında her iterasyondaki hata sayısını verir.
294         print("Error count on ", i + 1, "th iteration is: ", changeCount)
295
296         #Eğitim hatasız ise eğitimi durdurur.
297         if changeCount == 0:
298             finaliter = i+1
299             finalw = w
300             break
301
302     #Sonuç olarak başlanılan ağırlık vektörü, son eğitimdeki iterasyon sayısı, son ağırlık vektörü ve son iterasyondaki değişim sayısını verir.
303     final = [firstw, finaliter, finalw, totalEdError]
304     return final

```

Daha sonra güncellenen ağırlık test aşamasına girer. Bu, eğitim fonksiyonuyla aynı karşılaştırmayı yapar fakat ağırlıkları güncellemez. Yalnızca $yd = y$ karşılaştırması yapıp farklı çıkınca errorCount değerini 1 artırır. Test sırasında hata bulunmuşsa balanceDomain fonksiyonu ile eğitim kümesi ve test kümesinden birer eleman yer değiştirir. Bu değişim, rastgele olmasına rağmen iki veri sınıfının test ve eğitim kümesinde bulunan elemanlarının sayılarını yakınlatacak şekilde ağırlıklandırılmıştır. process fonksiyonunda errorCount = 0 olmadıkça veya hatalı test ya da eğitim sayısı maxiter değerini aşmadıkça eğitim-test döngüsü devam eder.

```

137 def test(List, w):
138     #Eğitim fonksiyonuyla hemen hemen aynı algoritmaya sahip. Aralarındaki fark test fonksiyonunun ağırlığı değiştirmeyip yalnızca hata sayısına bakması.
139     testList = []
140     errorCount = 0
141     for obj in List:
142         if GetDomain(obj) == "test":
143             testList.append(obj)
144
145     for obj in testList:
146         biasCoord = np.concatenate((GetCoordinate(obj),[1]))
147         v = np.dot(w, biasCoord)
148         if v > 0:
149             y = 1
150         else:
151             y = -1
152         yd = GetDataClass(obj)
153         if yd != y:
154             errorCount += 1
155     #Test sonucu elde edilen hata sayısını döndürür.
156     result = errorCount
157     return result
158
159 #Normal dağılımlı rastgele bir ağırlık vektörü atar.
160 def getRandomw(mean, scale):
161     w = np.random.normal(mean, scale, 6)
162     return w

```

```

90 #Eğitim ve Test kümesi arasında eleman alışverişinde bulunur.
91 def balanceDomain(List):
92     Class1Education = []
93     Class2Education = []
94     Class1Test = []
95     Class2Test = []
96
97     for obj in List:
98         if GetDataClass(obj) == 1:
99             if GetDomain(obj) == "education":
100                 Class1Education.append(obj)
101             elif GetDomain(obj) == "test":
102                 Class1Test.append(obj)
103             else:
104                 print("None domain object detected.")
105         elif GetDataClass(obj) == -1:
106             if GetDomain(obj) == "education":
107                 Class2Education.append(obj)
108             elif GetDomain(obj) == "test":
109                 Class2Test.append(obj)
110             else:
111                 print("None domain object detected.")
112         else:
113             print("None class object detected.")
114
115     #(0,1) arasında normal dağılımlı rastgele bir c sayısı seçer. Daha sonra bu sayıyı kümelerin eleman sayılarıyla karşılaştırır.
116     c = np.random.normal(0.5, 0.1, 1)
117
118     #Eğer birinci veri sınıfına ait eğitim kümesi elemanlarının sayısı, ikinciye ait olanlardan fazlaysa c'nin aşağıdaki değerden küçük olma olasılığı fazladır.
119
120     if c < len(Class1Education)/(len(Class1Education)+len(Class2Education)):
121         #Bu durumda eğitim kümesinden birince sınıfa ait bir eleman çıkarılıp test kümesine aktarılır.
122         item = random.choice(Class1Education)
123         item.setDomain("test")
124         #Küme sayılarının aynı kalması için test kümesinden ikinci sınıfa ait bir eleman çıkarılıp eğitim kümesine aktarılır.
125         item = random.choice(Class2Test)
126         item.setDomain("education")
127         #Aksi takdirde ise aynı işlem sınıflar değiştirilerek gerçekleştirilir.
128     else:
129         item = random.choice(Class2Education)
130         item.setDomain("test")
131         item = random.choice(Class1Test)
132         item.setDomain("education")
133         #Sonuçta ortaya çıkan kümelerin öncekilere göre daha iyi olma garantisi yoktur ancak c için verdiğimiz koşul
134         #ortaya çıkan kümelerin daha iyi olması ihtimalini yükseltir.

```

process fonksiyonu sonuncunda kaç testin başarısız olduğu, hangi iterasyonda eğitimin gerçekleştiği ve son ağırlık vektörü görülür. Başarısız test sayısı, iterasyon başına ortalama hata, iterasyon sayısı, ilk ağırlık, son ağırlık ve ilk ve son ağırlıkların oranı bilgileri elde edilir.

```

305 #Eğitim ve test işlemlerinin gerçekleştiği fonksiyon
306 def process(objList, w, c, maxIter, domainFile):
307     i = 0
308     failedTestCount = 0
309     totalEdError = 0
310     wantedInfo = []
311     w = np.array(w)
312     #Önceden belirli bir eğitim-test kümesi dağılımı yapar. Yukarıda belirtilen domainFile1'deki eğitim-test kümesini çeker.
313 > if domainFile != None: ...
319 #Eğer önceden belirli bir eğitim-test kümesi yoksa, girilen datayı dağıtır. Bu sayede kümeleri belirtilmeyen her veri rastgele kümelere dağıtılır.
320 > else: ...
322
323 > while i < 1: ...
357 #Test-Eğitim kümesi değişim sayısı
358 print("Failed Test Count:", failedTestCount)
359
360 #Eğitim sonucu elde edilen eğitim-test kümesi elemanları çekilir ve domainFile dosyasına kaydedilir.
361 if domainFile != None:
362     extractDomain(objList, domainFile)
363
364 #Eğer eğitim tamamlanmamışsa
365 if len(final) == 4:
366     print("Educated on: ", final[1], "th iteration.")
367     print("Final weight: ", final[2])
368     iterAmount = final[1]
369     avgErrorPerIter = totalEdError/iterAmount
370     magFirst = np.linalg.norm(final[0])
371     magFinal = np.linalg.norm(final[2])
372     magRatio = magFinal/magFirst
373     wantedInfo = [failedTestCount, avgErrorPerIter, iterAmount, magFirst, magFinal, magRatio]
374     return wantedInfo

```

w = [1, 1, 1, 1, 1, 1] için c = 1 eğitim hızıyla daha önce belirtilen DomainEx1 küme dağılımıyla eğitim yapıldığında şu sonuç elde edilir:

```

Test number: 1
First weight: [1 1 1 1 1]
Error count on 1 th iteration is: 7
Error count on 2 th iteration is: 5
Error count on 3 th iteration is: 3
Error count on 4 th iteration is: 4
Error count on 5 th iteration is: 3
Error count on 6 th iteration is: 3
Error count on 7 th iteration is: 2
Error count on 8 th iteration is: 2
Error count on 9 th iteration is: 4
Error count on 10 th iteration is: 1
Error count on 11 th iteration is: 4
Error count on 12 th iteration is: 3
Error count on 13 th iteration is: 4
Error count on 14 th iteration is: 3
Error count on 15 th iteration is: 2
Error count on 16 th iteration is: 3
Error count on 17 th iteration is: 3
Error count on 18 th iteration is: 3
Error count on 19 th iteration is: 1
Error count on 20 th iteration is: 2
Error count on 21 th iteration is: 2
Error count on 22 th iteration is: 0
Tested error count of 1 th education is 0
Failed Test Count: 0
Educated on: 22 th iteration.
Final weight: [ 1.5964  0.8325  2.1872 -1.2123 -21.1314  23. ]

```

Bu işlem rastgele bir w ve küme dağılım argümanlarıyla gerçekleştirilince örnek olarak böyle bir sonuç elde edilebilir. `balanceDomain` fonksiyonu rastgele çalıştığı için, doğru bir test-eğitim kümesi dağılımı kullanmadan aynı argümanlarla aynı sonuçları tekrarlama ihtimali çok düşüktür.

```
413 #objList listesindeki verileri rastgele bir ilk ağırlıklarla ve c = 1 öğrenme hızı ile, maksimum 80 iterasyon sürece şekilde eğiten fonksiyon.
414 #domainFile kısmı "None" olduğu için eğitim sonucunda eğitim-test kümesi dağılımını kaydetmeyecek.
415 """print("\n\nTest number:", testnum, "_"*150, "\n")"""
416 testnum += 1
417 Inf = process(objList, [], 1, max_epoch*2, None)
418 """print("_"*165, "\n")"""
```


```
Test number: 2

First weight: [-1.6365 -1.4241 -1.0518  1.4459 -1.0647  0.7225]
Error count on 1 th iteration is: 6
Error count on 2 th iteration is: 0
Tested error count of 1 th education is 2
Error count on 1 th iteration is: 0
Tested error count of 2 th education is 2
Error count on 1 th iteration is: 0
Tested error count of 3 th education is 2
Error count on 1 th iteration is: 0
Tested error count of 4 th education is 2
Error count on 1 th iteration is: 1
Error count on 2 th iteration is: 3
Error count on 3 th iteration is: 2
Error count on 4 th iteration is: 2
Error count on 5 th iteration is: 3
Error count on 6 th iteration is: 2
Error count on 7 th iteration is: 2
Error count on 8 th iteration is: 3
Error count on 9 th iteration is: 3
Error count on 10 th iteration is: 1
Error count on 11 th iteration is: 3
Error count on 12 th iteration is: 0
Tested error count of 5 th education is 1
Error count on 1 th iteration is: 4
Error count on 2 th iteration is: 3
Error count on 3 th iteration is: 4
Error count on 4 th iteration is: 1
Error count on 5 th iteration is: 3
Error count on 6 th iteration is: 3
Error count on 7 th iteration is: 4
Error count on 8 th iteration is: 3
Error count on 9 th iteration is: 4
Error count on 10 th iteration is: 3
Error count on 11 th iteration is: 4
Error count on 12 th iteration is: 0
Tested error count of 6 th education is 0
Failed Test Count: 5
Educated on: 12 th iteration.
Final weight: [ 1.1645 -0.4102  0.3968 -0.4178 -19.8912  25.7225]
```

Eğer rastgele seçilen bir ağırlık vektörü ve önceden belirlenmiş bir dağılım kümesi için sadece eğitim hızı değiştirilerek ölçüm alınır. Bu 40 kez gerçekleştirilip elde edeceğimiz sonuçların ortalaması SpeedResult.json dosyasında saklanır.

```
426 domainFile3 = os.path.join(__location__, 'DomainEx3.pkl')
427 domainFile4 = os.path.join(__location__, 'DomainEx4.pkl')
428 # İlk olarak rastgele seçilen bir w = w3 ile aynı veri üzerinde öğrenme hızı değiştirilerek:
429 # Başarısız test sayısı
430 # Son eğitimdeki iterasyon başına düşen ortalama hata sayısı
431 # Son eğitimdeki iterasyon sayısı
432 # Son eğitimdeki başlangıç ağırlık vektörünün boyutu
433 # Son eğitimdeki bitiş ağırlık vektörünün boyutu
434 # Son eğitimdeki bitiş ve başlangıç ağırlık vektörlerinin oranı
435 # karşılaştırılır. Bu 40 kez, c = (0.1,4) aralığında 0.1 aralıklarla gerçekleştirilir.
436 w3 = getrandomw(0, 1)
437 cTestResults = []
438 resultFileC = os.path.join(__location__, 'SpeedResult.json')
439 for i in range(40):
440
441     #Rastgele dağıtılmış DomainEx3 dağılımını kullanır.
442     #DomainEx3'ün değişmemesi için bu dağılım DomainEx4'ye aktarılır.
443     insertDomain(objList, domainFile3)
444     extractDomain(objList, domainFile4)
445     #Elde ettiğimiz değerleri cTestResults'ta toplayıp döngü sonunda SpeedResult.json adlı dosyaya kaydederiz.
446     c = i/10 + 0.1
447     Inf = process(objList, w3, c, max_epoch*2, domainFile4)
448     Inf.append(c)
449     cTestResults.append(Inf)
450
451 for i in range(39):
452     w3 = getrandomw(0, 1)
453     for result in cTestResults:
454         insertDomain(objList, domainFile3)
455         extractDomain(objList, domainFile4)
456         c = result[6]
457         Inf = process(objList, w3, c, max_epoch*2, domainFile4)
458         Inf.append(c)
459         for i in range(len(result)):
460             if Inf[2] != -1:
461                 result[i] = (Inf[i] + result[i])/2
462 with open(resultFileC, 'w') as json_file:
463     json.dump(cTestResults, json_file)
```


Sonuçlara bakılırsa, hata sayısı her zaman 0'da kalmıştır. Bu seçilen kümelerin iyi dağılmasından kaynaklanır. Bu şekilde kümeleri dengelemeye gerek kalmaz.




Her eğitim iterasyonunda meydana gelen ortalama hataya bakıldığında, 3 ile 4 arasında devam ettiği görülmektedir. Çok küçük eğitim hızı değerlerinde yüksektir, 0.3 ve 1 aralığında optimal değerlere sahiptir ve sonrasında tekrar yükselir. Buna rağmen büyük farklılık göstermez.



Son eğitimdeki iterasyon sayılarına bakıldığında, grafiğin oldukça dalgalı olmasına rağmen $c = 2.8$ ve üzeri eğitim hızlarının 13 civarı iterasyonda eğitimi tamamladığı ve önceki değerlerden oldukça hızlı olduğu gözlemlenir. Eğitim hızının yükselmesiyle eğitimin hızlanması beklendiktir.



Son eğitimdeki ilk ağırlık vektörünün büyüklüğüne bakılırsa sabit olduğu gözlenir. eğitim esnasında test kümesi hiç başarısız olmadığı için aynı ağırlık vektörü kullanılmıştır. Bu sebeple ilk ağırlık vektörü her zaman testin başında seçilen w_3 vektörü olacaktır. Bu vektörün büyüklüğü 2.0188 değerindedir.



Son ağırlık vektörünün büyüklüğüne bakılırsa lineer olarak arttığı gözlenir. Eğitim sırasında iterasyon sayısının hıza göre çok da fazla değişmemesi ve ağırlık vektörü güncellenirken eğitim hızıyla doğru orantılı bir şekilde büyümesi bunu sağlar. İlk ağırlık vektörü tüm hızlarda sabit olduğu için aynı grafik son-ilk ağırlık vektörü oranlarında da görülür.




Her seferinde rastgele bir ağırlık vektörü seçip önceden belirlenmiş bir dağılım kümesi ve sabit eğitim hızı kullanır ve sonuçlar ilk seçilen ağırlık vektörünün büyüklüğüyle karşılaştırılır. Bu 40 kez gerçekleştirilip elde edeceğimiz sonuçların ortalaması WeightResult.json dosyasında saklanır.

```
467 domainFile5 = os.path.join(__location__, 'DomainEx5.pkl')
468 domainFile6 = os.path.join(__location__, 'DomainEx6.pkl')
469 # Daha sonra hız c = 1 ve aynı eğitim-test kümesiyle başlayıp farklı ağırlık vektörleriyle:
470 # Başarısız test sayısı
471 # Son eğitimdeki iterasyon başına düşen ortalama hata sayısı
472 # Son eğitimdeki iterasyon sayısı
473 # Son eğitimdeki başlangıç ağırlık vektörünün boyutu
474 # Son eğitimdeki bitiş ağırlık vektörünün boyutu
475 # Son eğitimdeki bitiş ve başlangıç ağırlık vektörlerinin oranı
476 # karşılaştırılır. Bu 40 kez, her döngüde farklı w değerleri alınarak gerçekleştirilir.
477 # Sonuç w vektörlerinin büyüklüklerine göre karşılaştırılacaktır.
478 wTestResults = []
479 resultFileW = os.path.join(__location__, 'WeightResult.json')
480 for i in range(40):
481     w4 = getrandomw(0, 1)
482     #Rastgele dağıtılmış DomainEx4 dağılımını kullanır.
483     #DomainEx5'in değişmemesi için bu dağılım DomainEx6'ya aktarılır.
484     insertDomain(objList, domainFile5)
485     extractDomain(objList, domainFile6)
486     #Elde ettiğimiz değerleri wTestResults'ta toplayıp döngü sonunda WeightResult.json adlı dosyaya kaydederiz.
487     Inf = process(objList, w4, 1, max_epoch*2, domainFile6)
488     Inf.append([np.linalg.norm(w4)])
489     wTestResults.append(Inf)
490
491 with open(resultFileW, 'w') as json_file:
492     json.dump(wTestResults, json_file)
```


Bu deneyde test kümesinden birkaç kez hata alınmıştır. Hatalı olan kümelerin ortalama 20 seferde dengelendiği görülür. Eğitim ve test kümeleri iyi dağılmıştır.



İterasyon başına düşen ortalama hata ilk ağırlık vektörünün büyüklüğünden ilişkisiz durmaktadır. Test kümesinin hatalı olduğu deneylerde düşük olduğu gözlemlenmektedir. Bunun sebebi test kümesindeki bir veya iki elemanın hatalı vermesi, bu elemanlar eğitim kümesine geçene kadar da ortalama hatanın düşmesidir.




Son eğitimin iterasyon sayısı da ilk ağırlık vektörünün büyüklüğünden ilişkisiz durmaktadır fakat test kümesinin hatalı olduğu deneylerde düşüktür. Bunun sebebi test ve eğitim kümelerinin, eğitim tamamlanana kadar optimize olmasıdır. Diğer deneylerde de eğitim tamamlanmasına rağmen, verimsiz kümeler kullanılmıştır.




Son eğitimin ilk ağırlık vektörü, hata olmadığı sürece ilk girilen ağırlık vektörünün büyüklüğüne eşittir. Hata yaşanan deneylerde ilk ağırlık gitgide büyümektedir.



İlginç bir şekilde son ağırlık vektörü büyüklüğü, hatalı testlerden ve ilk vektörün ağırlığından ilişkisiz bir sonuç vermektedir. Bu vektörün büyüklüğünü yalnızca veri setinin belirlediği gözlemlenir.





Son ağırlık vektörünün büyüklüğünün diğer parametrelerden ilişkisiz olması ve hatalı deneylerde ilk ağırlık vektörünün büyümesi sebebiyle, son eğitimin son-ilk ağırlık vektörleri büyüklükleri oranı çok düşük olacaktır. Bunun deneylerin dışında, yine son ağırlık vektörü nispeten sabit hareket ettiği için, ilk ağırlık vektörü büyüklüğü artarken son-ilk ağırlık vektörü büyüklükleri oranı düşmektedir.



Farklı eğitim kümesi sıralamalarına göre, eğitim hızı değişirken gözlem yapılır. Rastgele seçilmiş w4 ağırlık vektörü ve DomainEx7 küme dağılımı sabit tutulur.

```
496 domainFile7 = os.path.join(__location__, 'DomainEx7.pk1')
497 domainFile8 = os.path.join(__location__, 'DomainEx8.pk1')
498 # Son olarak aynı eğitim-test kümesi ve ağırlıklarla başlayıp
499 # eğitim kümesi vektörlerin büyüklüklerine göre farklı şekilde sıralandığında:
500 # Başarısız test sayısı
501 # Son eğitimdeki iterasyon başına düşen ortalama hata sayısı
502 # Son eğitimdeki iterasyon sayısı
503 # Son eğitimdeki başlangıç ağırlık vektörünün boyutu
504 # Son eğitimdeki bitiş ağırlık vektörünün boyutu
505 # Son eğitimdeki bitiş ve başlangıç ağırlık vektörlerinin oranı
506 # karşılaştırılır. Bu 40 kez c = (0.1,4) aralığında 0.1 değişirken eğitim kümesi
507 # elemanları büyükten küçüğe ve küçüktten büyüğe sıralıyken 40 kez test edilir ve karşılaştırılır.
508 w4 = getrandomw(0, 1)
509 sortTestResults = []
510 resultFileSort = os.path.join(__location__, 'SortResult.json')
511 for i in range(40):
512     #Rastgele dağıtılmış DomainEx6 dağılımını kullanır.
513     #DomainEx7'nin değişmemesi için bu dağılım DomainEx8'e aktarılır.
514     insertDomain(objList, domainFile7)
515     extractDomain(objList, domainFile8)
516     #Elde ettiğimiz değerleri sortTestResults'ta toplayıp döngü sonunda SortResult.json adlı dosyaya kaydederiz.
517     c = i/10 + 0.1
518     sort = "descending"
519     descList = sortList(objList, -1)
520     Inf = process(descList, w4, c, max_epoch*2, domainFile8)
521     Inf.append(c)
522     Inf.append(sort)
523     if Inf[2] != -1:
524         sortTestResults.append(Inf)
525
526     insertDomain(objList, domainFile7)
527     extractDomain(objList, domainFile8)
528     sort = "ascending"
529     ascList = sortList(objList, 1)
530     Inf = process(ascList, w4, c, max_epoch*2, domainFile8)
531     Inf.append(c)
532     Inf.append(sort)
533     if Inf[2] != -1:
534         sortTestResults.append(Inf)
535
536 for i in range(39):
537     for result in sortTestResults:
538         insertDomain(objList, domainFile7)
539         extractDomain(objList, domainFile8)
540         c = result[6]
541         Inf = process(objList, w4, c, max_epoch*2, domainFile8)
542         Inf.append(c)
543         Inf.append(sort)
544         for j in range(len(result)-1):
545             if Inf[2] != -1:
546                 result[j] = (Inf[j] + result[j])/2
547 with open(resultFileSort, 'w') as json_file:
548     json.dump(sortTestResults, json_file)
```


Sonuçlara bakıldığında, hatalı test sayısının yükselen sıralamada daha düşük olmasıyla birlikte iniş ve çıkışların sıralamadan fazla etkilenmediği görülür. Eğitim hızı 1.5-2.5 aralığında hatalı test sayısında bir artış vardır ve aralığın dışında genel olarak düşüktür.



İterasyon başına düşen hata da sıralamadan bağımsız olmakla birlikte, eğitim hızı 0.8-1.9 aralığında düşüktür.



Son eğitimde gerçekleşen iterasyon sayısı da verilerin sıralamasıdan etkilenmemektedir.



Son eğitimdeki ilk ağırlık vektörü de sıralamadan etkilenmemektedir. Büyüklüğü, yüksek ve düşük eğitim hızlarında, 1-3 aralığındakinden daha düşüktür.



Son eğitimin son ağırlık vektörü; ilk ağırlık vektörü, iterasyon sayısı ve eğitim hızıyla doğru orantılı olduğundan sıralamadan bağımsız bir şekilde, eğitim hızı arttıkça artmaktadır.



Son olarak, son ağırlık vektörlerinin ilk ağırlık vektörlerine oranı karşılaştırıldığında bunların da sıralamadan bağımsız olduğu görünür.



Sorunun diğer kısmı için malesef lineer ayrıştırılamaz bir veri seti elde edilemedi.


```
544 nonLinFile = os.path.join(__location__, 'NonLinearData.pkl')
545
546 if os.path.exists(nonLinFile):
547     nonLinList = loadList(nonLinFile)
548     nonLinDict = newDict(nonLinList)
549
550 else:
551     nonLinList = newData(max_epoch)
552     nonLinDict = newDict(nonLinList)
553     distDomain(nonLinList)
554     distClass(max_epoch, nonLinDict, nonLinList, 0)
555     saveData(nonLinList, nonLinFile)
556
557 #Sorunun ikinci kısmı için lineer ayrıştırılamaz bir küme oluşturulur. Kodun bu kısmı bilinmeyen bir hatadan dolayı çalışmamakta.
558 #Verilerin kümeleri karışıyor ve eğitim kümesi anında eğitiliyor.
559 Inf = process(nonLinList, [], 1, max_epoch*2, nonLinFile)
560 domainTest(nonLinList)
561 #Verilerin son halini kaydeder
562 saveData(nonLinList, nonLinFile)
563 saveData(objList, dataFile)
564
```

```
First weight: [-1.1096  0.7838 -1.1416  0.7309  0.7168 -1.1141]
Tested error count of 1 th education is 0
Failed Test Count: 0
Educated on: 1 th iteration.
Final weight: [-1.10957975  0.78384397 -1.14157372  0.73091549  0.71676368 -1.11405434]
-1 -1 -1 -1 1 -1 -1 1 -1 1 1 1 -1 1 1 -1 -1 -1 1 1 1 1 -1 -1 -1 1 -1 -1 -1 1 -1 1 1 1 1 1 -1 1
E1 count: 20 T1 count: 0
E2 count: 20 T2 count: 0
PS D:\Mehmet\Python> █
```


Soru 2:

Bu soru diğerlerinden farklı olarak MATLAB üzerinden çözülmüştür.

Veriler çizildiğinde, lineer ayrıştırılamadığı görülebiliyor. Lineer ayrıştırılabilir hale getirmek için verilere yeni bir boyut eklenir, bu şekilde üç boyutlu bir uzayda veriler bir düzlem ile ayrıştırılabilir.



Bunun için birçok düzlem seçilebilir. Bizim seçtiğimiz düzlem, verilerle aynı z koordinatındayken $r = 2$ çemberi kesitine sahip koni düzlemi oldu.



Bu işlemlerin yapıldığı MATLAB kodu aşağıdaki gibidir.

```
1 - i = 1;
2 - A = zeros(24,4);
3 - B = zeros(9,4);
4
5 - %Yd = -1 olan veri matrisi
6 - for x = -3:3
7 -     for y = -3:3
8 -         if (abs(x) == 3) || (abs(y) == 3)
9 -             A(i,:) = [x;y;1;1];
10 -             i = i+1;
11 -         end
12 -     end
13 - end
14
15 - %Yd = 1 olan veri matrisi
16 - i = 1;
17 - for x = -1:1
18 -     for y = -1:1
19 -         B(i,:) = [x;y;1;1];
20 -         i = i+1;
21 -     end
22 - end
23
24 - %Çember tanımlanıyor.
25 - r = linspace(0,10) ;
26 - th = linspace(0,2*pi) ;
27 - [R,T] = meshgrid(r,th) ;
28 - X = R.*cos(T) ;
29 - Y = R.*sin(T) ;
30 - %Verilere Z = 1 boyutu eklendiği için
31 - %Z = 1 => R = 2 olması isteniyor. R, Z'ye bağımlı olduğu için bir koni
32 - %düzlemi tanımlanıyor.
33 - Z = R - 1 ;
34
35 - s1 = surf(X,Y,Z,'FaceAlpha',0.8,'EdgeAlpha',0.2,'FaceColor',[50 255 50]/255);
36 - xlabel('x');
37 - ylabel('y');
38 - zlabel('z');
39 - hold on
40 - plot3(A(:,1),A(:,2),A(:,3),'x','MarkerEdgeColor','b');
41 - plot3(B(:,1),B(:,2),B(:,3),'o','MarkerEdgeColor','r');
42 - hold off
```

Soru 3:

$f(x_1, x_2) = 3x_1 + 2\cos(x_2)$ fonksiyonu $x_1 = [0,1]$ ve $x_2 = [0, \pi/2]$ aralığındayken yaklaşık olarak ifade edilmeli. Fonksiyonun minimumu $f(0, \pi/2) = 0$, maksimumu $f(1, 0) = 5$. $g(x_1, x_2) = f(x_1, x_2)/5$ fonksiyonu tanımlanıp kullanılırsa $[0,1]$ aralığını kapsayacak logit Adaline fonksiyonu kullanarak yaklaşılabılır. $\phi(v) = \frac{1}{1+e^{-v}}$
($x_1w_1 + x_2w_2 + 1w_3 = v$)

Veri setinin oluşumu için rastgele 100 farklı x_1 - x_2 seti seçilir, rastgele bir şekilde test ve eğitim kümelerine dağıtılır ve veriler oluşturulur.

```
15 class DataPoints:
16     #DataPoints obje sınıfında koordinat, anahtar, veri sınıfı mevcut.
17     def __init__(self, Coordinate, Key, Domain):
18         self.Coordinate = Coordinate
19         self.Key = Key
20         self.Domain = Domain
21
22     def setDomain(self, Domain):
23         self.Domain = Domain
24
25     def setCoordinate(self, Coordinate):
26         self.Coordinate = Coordinate
27
28
29
30
31
32
33
34
35
36
37 __location__ = os.path.realpath(os.path.join(os.getcwd(), os.path.dirname(__file__)))
38 dataFile = os.path.join(__location__, 'DataQ3.pkl')
39 max_epoch = 100
40
41 GetCoordinate = attrgetter('Coordinate')
42 GetKey = attrgetter('Key')
43 GetDomain = attrgetter('Domain')
44
45 if os.path.exists(dataFile):
46     objList = loadList(dataFile)
47
48 else:
49     objList = newData(max_epoch)
50     distDomain(objList)
51     saveData(objList, dataFile)
52
53
54
55
56
57
58
59
60
61
62
63
64
65
66
67
68
69
70
71
72
73
74
75
76
77
78
79
80
81
82
83
84
85
86
87
88
89
90
91
92
93
94
95
96
97
98
99
100
101
102
103
104
105
106
107
108
109
110
111
112
113
114
115
116
117
118
119
120
121
122
123
124
125
126
127
128
129
130
131
132
133
134
135
136
137
138
139
140
141
142
143
144
145
146
147
148
149
150
151
152
153
154
155
156
157
158
159
160
161
162
163
164
165
166
167
168
169
170
171
172
173
174
175
176
177
178
179
180
181
182
183
184
185
186
187
188
189
190
191
192
193
194
195
196
197
198
199
200
201
202
203
204
205
206
207
208
209
210
211
212
213
214
215
216
217
218
219
220
221
222
223
224
225
226
227
228
229
230
231
232
233
234
235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251
252
253
254
255
256
257
258
259
260
261
262
263
264
265
266
267
268
269
270
271
272
273
274
275
276
277
278
279
280
281
282
283
284
285
286
287
288
289
290
291
292
293
294
295
296
297
298
299
300
301
302
303
304
305
306
307
308
309
310
311
312
313
314
315
316
317
318
319
320
321
322
323
324
325
326
327
328
329
330
331
332
333
334
335
336
337
338
339
340
341
342
343
344
345
346
347
348
349
350
351
352
353
354
355
356
357
358
359
360
361
362
363
364
365
366
367
368
369
370
371
372
373
374
375
376
377
378
379
380
381
382
383
384
385
386
387
388
389
390
391
392
393
394
395
396
397
398
399
400
401
402
403
404
405
406
407
408
409
410
411
412
413
414
415
416
417
418
419
420
421
422
423
424
425
426
427
428
429
430
431
432
433
434
435
436
437
438
439
440
441
442
443
444
445
446
447
448
449
450
451
452
453
454
455
456
457
458
459
460
461
462
463
464
465
466
467
468
469
470
471
472
473
474
475
476
477
478
479
480
481
482
483
484
485
486
487
488
489
490
491
492
493
494
495
496
497
498
499
500
501
502
503
504
505
506
507
508
509
510
511
512
513
514
515
516
517
518
519
520
521
522
523
524
525
526
527
528
529
530
531
532
533
534
535
536
537
538
539
540
541
542
543
544
545
546
547
548
549
550
551
552
553
554
555
556
557
558
559
560
561
562
563
564
565
566
567
568
569
570
571
572
573
574
575
576
577
578
579
580
581
582
583
584
585
586
587
588
589
590
591
592
593
594
595
596
597
598
599
600
601
602
603
604
605
606
607
608
609
610
611
612
613
614
615
616
617
618
619
620
621
622
623
624
625
626
627
628
629
630
631
632
633
634
635
636
637
638
639
640
641
642
643
644
645
646
647
648
649
650
651
652
653
654
655
656
657
658
659
660
661
662
663
664
665
666
667
668
669
670
671
672
673
674
675
676
677
678
679
680
681
682
683
684
685
686
687
688
689
690
691
692
693
694
695
696
697
698
699
700
701
702
703
704
705
706
707
708
709
710
711
712
713
714
715
716
717
718
719
720
721
722
723
724
725
726
727
728
729
730
731
732
733
734
735
736
737
738
739
740
741
742
743
744
745
746
747
748
749
750
751
752
753
754
755
756
757
758
759
760
761
762
763
764
765
766
767
768
769
770
771
772
773
774
775
776
777
778
779
780
781
782
783
784
785
786
787
788
789
790
791
792
793
794
795
796
797
798
799
800
801
802
803
804
805
806
807
808
809
810
811
812
813
814
815
816
817
818
819
820
821
822
823
824
825
826
827
828
829
830
831
832
833
834
835
836
837
838
839
840
841
842
843
844
845
846
847
848
849
850
851
852
853
854
855
856
857
858
859
860
861
862
863
864
865
866
867
868
869
870
871
872
873
874
875
876
877
878
879
880
881
882
883
884
885
886
887
888
889
890
891
892
893
894
895
896
897
898
899
900
901
902
903
904
905
906
907
908
909
910
911
912
913
914
915
916
917
918
919
920
921
922
923
924
925
926
927
928
929
930
931
932
933
934
935
936
937
938
939
940
941
942
943
944
945
946
947
948
949
950
951
952
953
954
955
956
957
958
959
960
961
962
963
964
965
966
967
968
969
970
971
972
973
974
975
976
977
978
979
980
981
982
983
984
985
986
987
988
989
990
991
992
993
994
995
996
997
998
999
1000
```


Ardından veri setiyle eğitim başlatılır. Eğitim için $w1 = [1 \ 1 \ 1]$ ağırlık vektörü ve $c = 0.5$ eğitim hızı kullanılır. Eğitim, ortalama kare hatasının önceki iterasyonla farkı, kendisinin 10^{-12} katından aşağıya düşmedikçe devam edecektir. Ayrıca bu koşul sağlandıktan sonra test döngü tekrar gerçekleşir ve test kümesinde aynı koşulun sağlanması gerekir. Bununla birlikte eğitim tamamlanır.

```
59 def educate(objList, w, c):
60     print("İlk ağırlık vektörü:", w)
61     count = 1
62     countT = -1
63     i = 0
64     Eortprev = 0
65     EortIprev = 0
66     Eort = 0
67     w = np.array(w)
68     while i < 1:
69         E = 0
70         for obj in objList:
71             if GetDomain(obj) == "E":
72                 Coord = GetCoordinate(obj)
73                 yd = f(Coord[0], Coord[1])/5
74                 v = np.dot(w, Coord)
75                 y = phi(v)
76                 e = yd - y
77                 E += (1/2)*(e**2)
78                 phiDerivative = phi(v)*(1 - phi(v))
79                 w = w + e*phiDerivative*Coord
80         Eort = E/len(objList)
81         EortR = Eort
82         if abs(Eort - Eortprev) < Eort/(10**12):
83             i += 1
84
85         if i == 1:
86             E = 0
87             for obj in objList:
88                 if GetDomain(obj) == "T":
89                     yd = f(Coord[0], Coord[1])/5
90                     v = np.dot(w, Coord)
91                     y = phi(v)
92                     e = yd - y
93                     E += (1/2)*(e**2)
94             Eort = E/len(objList)
95             if abs(Eort - EortIprev) < Eort/(10**12):
96                 i += 1
97             else:
98                 countT += 1
99
100         EortIprev = Eort
101         print("İterasyon:", count, "\tOrtalama hata:", EortR, "\tAğırlık vektörü:", w)
102
103         count += 1
104         Eortprev = Eort
105         Eort = 0
106         if countT > 0:
107             print("Başarısız Test Sayısı:", countT)
108         result = [w, count, EortR]
109         return result
```

Eğitim sırasında her iterasyonda her veri için $y_d = f(x_1, x_2)/5$ değeri hesaplanır. Daha sonra $w^T \cdot x$ ile v bulunup $\phi(v)$ değeri elde edilir. $e = y_d - y$ hesaplanıp toplam veri hatası $E = (1/2) \cdot e^2$, iterasyonun toplam hatası E' 'ye eklenir. $\phi(v)$ fonksiyonu türevi hesaplanır. Ardından bu değerler ağırlık vektörünün güncellenmesi için $w = w + e \cdot \phi_{\text{Derivative}} \cdot \text{Coord}$ şeklinde toplanır. Daha sonra w güncellenmeden, aynı işlem test kümesinde yapılır.

```
while i < 1:
    E = 0
    for obj in objList:
        if GetDomain(obj) == "E":
            Coord = GetCoordinate(obj)
            yd = f(Coord[0], Coord[1])/5
            v = np.dot(w, Coord)
            y = phi(v)
            e = yd - y
            E += (1/2)*(e**2)
            phiDerivative = phi(v)*(1 - phi(v))
            w = w + e*phiDerivative*Coord
    Eort = E/len(objList)
    EortR = Eort
    if abs(Eort - Eortprev) < Eort/(10**12):
        i +=1
```


```
if i == 1:
    E = 0
    for obj in objList:
        if GetDomain(obj) == "T":
            yd = f(Coord[0], Coord[1])/5
            v = np.dot(w, Coord)
            y = phi(v)
            e = yd - y
            E += (1/2)*(e**2)
    Eort = E/len(objList)
    if abs(Eort - EortTprev) < Eort/(10**12):
        i +=1
    else:
        countT += 1

    EortTprev = Eort
    print("İterasyon:", count, "\tOrtalama hata:", EortR, "\tAğırlık vektörü:", w)
    count += 1
    Eortprev = Eort
    Eort = 0
if countT > 0:
    print("Başarısız Test Sayısı:", countT)
result = [w, count, EortR]
return result
```

Kod çalıştığında 199. İterasyonda başarılı olup, yaklaşık %0.02266 ortalama hata ile eğitimin tamamlandığı görülür. Son ağırlık vektörü $w = [2.76695842 -1.2814749 -0.09802192]$ elde edilir.

```
İterasyon: 192 Ortalama hata: 0.0002266322612325632 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 193 Ortalama hata: 0.0002266322612329429 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 194 Ortalama hata: 0.0002266322612332801 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 195 Ortalama hata: 0.00022663226123358028 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 196 Ortalama hata: 0.00022663226123384748 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 197 Ortalama hata: 0.0002266322612340848 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
İterasyon: 198 Ortalama hata: 0.00022663226123429594 Ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192]
Son ağırlık vektörü: [ 2.76695842 -1.2814749 -0.09802192] İterasyon sayısı: 199 Son İterasyonda ortalama hata: 0.00022663226123429594
```

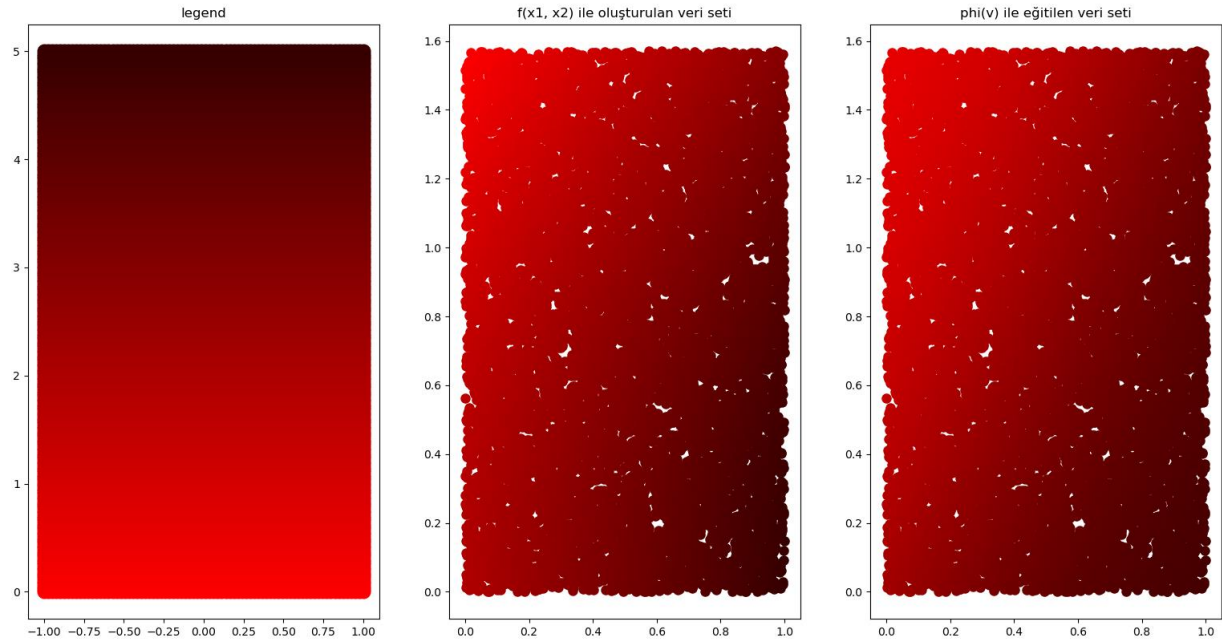
Ek olarak, sonuçlar çizdirilmek istenirse aşağıdaki şekil elde edilir.



Buradan da eğitilen sistemin istenilen fonksiyona yakınlığı gözlemlenebilir. Daha iyi gözlem yapabilmek için veri sayısını artırırsak, örneğin 10000 veri alırsak eğitimin çok daha hızlı gerçekleştiğini görürüz. Aynı parametrelerle işlem yapıldığında yeni veri setiyle eğitim 5. İterasyonda gerçekleşir. Elde edilen son ağırlık [2.72203588 - 1.25285761 -0.1246531] ve yaklaşık ortalama hata oranı %0.023575 olarak gözlemlenir.

```
İlk ağırlık vektörü: [1 1 1]
İterasyon: 1 Ortalama hata: 0.0005214433184262373 Ağırlık vektörü: [ 2.72202975 -1.25285643 -0.12465089]
İterasyon: 2 Ortalama hata: 0.0002357527208975145 Ağırlık vektörü: [ 2.72203588 -1.25285761 -0.1246531 ]
İterasyon: 3 Ortalama hata: 0.00023575270154065731 Ağırlık vektörü: [ 2.72203588 -1.25285761 -0.1246531 ]
İterasyon: 4 Ortalama hata: 0.00023575270154056508 Ağırlık vektörü: [ 2.72203588 -1.25285761 -0.1246531 ]
Son ağırlık vektörü: [ 2.72203588 -1.25285761 -0.1246531 ] İterasyon sayısı: 5 Son iterasyonda ortalama hata: 0.00023575270154056508
```

Hata oranının önceki deneyden yüksek olması, fonksiyonun yaklaşılmaya çalışıldığı çok daha fazla veriye sahip olmasından kaynaklanır. Buna rağmen iki fonksiyon arasındaki yakınlık, sonuçlar çizdirilince gözlemlenebilir.



Soru 4:

Genlikte sürekli algılayıcı ile böyle bir fonksiyonun elde edilebilmesi için, seçilecek aktivasyon fonksiyonu $\phi(v)$ de bu tipte olmalıdır. $v = w_1x_1 + w_2x_2 + \dots + w_nx_n + w_{(n+1)}$ olarak açılırsa, $\phi(v)$ fonksiyonunun

$$f(x_1, x_2, \dots, x_n) = \sum_{k=i} c_i x_i + \sum_{k=i} \sum_{k=i} c_{ij} x_i x_j \quad \text{gibi bir fonksiyona benzetilmesi}$$


için verilen x_1 ve x_2 aralığı için $\phi(v) = \tanh(v)$ aktivasyon fonksiyonu kullanılabilir.

```
def phi(v):  
    return abs(np.tanh(v))
```

```
while i < 1:  
    E = 0  
    for obj in objList:  
        if GetDomain(obj) == "E":  
            Coord = GetCoordinate(obj)  
            yd = f(Coord[0], Coord[1])/5  
            v = np.dot(w, Coord)  
            y = phi(v)  
            e = yd - y  
            E += (1/2)*(e**2)  
            phiDerivative = np.sinh(v)/(abs(np.sinh(v)/np.cosh(v))*(np.cosh(v)**3))  
            w = w + e*phiDerivative*Coord  
    Eort = E/len(objList)  
    EortR = Eort  
    if abs(Eort - Eortprev) < Eort/(10**12):  
        i += 1
```


Bu şekilde bir eğitim gerçekleştirildiğinde önceki sorudaki 100 verilik veri seti ile 21 iterasyonda yaklaşık %0.1148 hata ile eğitim tamamlanır ve son ağırlık vektörü [0.86449066 -0.4097381 0.59531946] bulunur. Elde edilen veri çizdirildiğinde, birbirine yakın çizimler ortaya çıkar.

```
İterasyon: 15 Ortalama hata: 0.0011480737359049632 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
İterasyon: 16 Ortalama hata: 0.0011480737361513934 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
İterasyon: 17 Ortalama hata: 0.001148073736204048 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
İterasyon: 18 Ortalama hata: 0.0011480737362152967 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
İterasyon: 19 Ortalama hata: 0.001148073736217701 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
İterasyon: 20 Ortalama hata: 0.0011480737362182126 Ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946]
Son ağırlık vektörü: [ 0.86449066 -0.4097381 0.59531946] İterasyon sayısı: 21 Son iterasyonda ortalama hata: 0.0011480737362182126
```



Eğitim 10000 verilik veri seti ile gerçekleştirildiğinde ise 4. İterasyonda yaklaşık %0.1803 hata oranı ile eğitim tamamlanır ve son ağırlık vektörü $[-0.88434009 \ 0.39164808 \ -0.52397232]$ bulunur. Bu veri çizdirilince yine birbirine yakın şekiller ortaya çıkar.

```
İlk ağırlık vektörü: [1 1 1]
İterasyon: 1 Ortalama hata: 0.001979286490299345 Ağırlık vektörü: [-0.88434009 0.39164808 -0.52397232]
İterasyon: 2 Ortalama hata: 0.001802687739602909 Ağırlık vektörü: [0.88434009 -0.39164808 0.52397232]
İterasyon: 3 Ortalama hata: 0.001802687739602909 Ağırlık vektörü: [-0.88434009 0.39164808 -0.52397232]
Son ağırlık vektörü: [-0.88434009 0.39164808 -0.52397232] İterasyon sayısı: 4 Son iterasyonda ortalama hata: 0.001802687739602909
```



Sonuca bakacak olursak w vektörü yaklaşık olarak ilk veri setiyle

$$w = [0.8645 \ -0.4097 \ 0.5953] = [w_{11} \ w_{12} \ w_{13}]$$

ikinci veri setiyle

$$w = [-0.8843 \ 0.3917 \ -0.524] = [w_{21} \ w_{22} \ w_{23}]$$

bulunmuştur. Fonksiyona koyulduğunda

$$\phi(v) = \phi(w_1 \cdot x_1 + w_2 \cdot x_2 + w_3 \cdot x_1 \cdot x_2) = c_1 \cdot x_1 + c_2 \cdot x_2 + c_3 \cdot x_1 \cdot x_2 = f(x_1, x_2) \text{ elde edilir.}$$

İki tarafında;

$$x_1 \text{'e göre türevi alındığında } \phi'(v) \cdot w_1 = c_1 + c_3 \cdot x_2$$

x_2 'ye göre türevi alındığında $\phi'(v) \cdot w_2 = c_2 + c_3 \cdot x_1$ olacaktır. c_1 ve c_2 x_1 ve x_2 'ye bağımlıdır.


Wolfram kullanılarak ilk veri seti için çizildiğinde $c_{11} + c_{13}x_2$:

plot	$\frac{\partial(0.8645 \tanh(0.59532 + 0.8645 x_1 - 0.4097 x_2))}{\partial x_1}$	$x_1 = 0 \text{ to } 1$
		$x_2 = 0 \text{ to } \frac{\pi}{2}$

tanh

3D plot:

 Enla




c12 + c13*x1:

Input interpretation:

plot	$\frac{\partial(-0.4097 \tanh(0.59532 + 0.8645 x_1 - 0.4097 x_2))}{\partial x_1}$	$x_1 = 0 \text{ to } 1$
		$x_2 = 0 \text{ to } \frac{\pi}{2}$

tanh(x) is

3D plot:




İkinci veri seti için $c_{21} + c_{23}x_1$:

plot	$\frac{\partial(-0.8843 \tanh(-0.524 - 0.8843 x_1 + 0.3917 x_2))}{\partial x_1}$	$x_1 = 0 \text{ to } 1$
		$x_2 = 0 \text{ to } \frac{\pi}{2}$

$\tanh(x)$

3D plot:




c22 + c23*x2:

plot	$\frac{\partial(0.3917 \tanh(-0.524-0.8843\,x_1+0.3917\,x_2))}{\partial x_1}$	$x_1 = 0 \text{ to } 1$
		$x_2 = 0 \text{ to } \frac{\pi}{2}$

tanf

3D plot:



Kullanılan kaynak ve kütüphaneler:

- Python
 - Numpy
 - Matplotlib
 - random
 - math
 - json
 - pickle
 - scipy
- WolframAlpha
- Stackoverflow

Kullanılan kodlara, ödev dosyasına ek olarak

<https://github.com/meserbetcioglu/ehb420hw1.git> linkini kullanarak erişebilirsiniz.